

Análisis de la Prima de Riesgo Griega: Un Enfoque Comparativo entre Econofísica y GARCH Bayesiano

Ismael Sallami Moreno[†], David Bacas Posadas[‡]

Abstract. Este trabajo analiza la dinámica estocástica de la prima de riesgo griega respecto al bono alemán, utilizando datos diarios que abarcan el periodo crítico de la crisis de deuda soberana. La justificación de este estudio radica en la necesidad de contrastar metodologías dispares para modelar riesgos extremos: el enfoque físico de difusión anómala y el enfoque econométrico estándar.

Nuestro objetivo es determinar si el mercado exhibe memoria a largo plazo o si se ajusta a los modelos de volatilidad condicional tradicionales. Para ello, utilizamos datos del diferencial de bonos a 10 años y aplicamos análisis de Desplazamiento Cuadrático Medio (MSPD) e inferencia Bayesiana mediante cadenas de Markov (MCMC).

Los hallazgos empíricos revelan un comportamiento super-difusivo ($\alpha \approx 0.94$), evidenciando una fuerte persistencia estructural, mientras que el modelo GARCH demuestra ser indispensable para capturar clústeres de volatilidad a corto plazo, a pesar de su complejidad computacional.

1. Análisis Empírico y Calibración de Modelos

1.1. Enfoques planteados en la literatura

En esta sección se presenta la calibración y validación comparativa de los dos enfoques propuestos: el modelo de Difusión Anómala, fundamentado en la Econofísica siguiendo a Alvarez-Ramirez et al. (Alvarez-Ramirez et al., 2002), y el modelo GARCH Bayesiano, estándar en la econometría financiera moderna (Bollerslev, 1986).

El conjunto de datos utilizado corresponde al diferencial de la prima de riesgo (spread) entre los bonos de Grecia y Alemania a 10 años. Tras el preprocesamiento, se identificó un máximo en la serie original de 1987.40 puntos básicos (bps), evidenciando la magnitud extrema de la crisis de deuda soberana griega (Arghyrou and Tsoukalas, 2011).

1.2. Modelo de Difusión y Ley de Potencia

Para evaluar la dinámica estocástica subyacente, se calculó el Desplazamiento Cuadrático Medio (MSPD) sobre la serie temporal. El objetivo es determinar si el proceso sigue una caminata aleatoria clásica (difusión normal) o exhibe un comportamiento anómalo con memoria a largo plazo.

El modelo ajustado responde a la ley de potencia característica de los sistemas complejos:

$$\langle (\Delta x)^2 \rangle \sim t^\alpha \quad (1)$$

Donde el exponente α determina la naturaleza de la difusión.

[†] ismaelsallami12@gmail.com.

[‡] davidbacasposadas@gmail.com.




Figure 1. Calibración del Modelo de Difusión en escala Log-Log. El ajuste lineal indica una adherencia robusta a la ley de potencia con $\alpha \approx 0.94$.

Como se observa en la Figura 1, el ajuste mediante Mínimos Cuadrados no lineales es notablemente preciso. Los resultados computacionales arrojan un exponente de difusión calibrado de:

$$\alpha = 0.9360$$

Este valor sugiere un comportamiento *super-difusivo* cercano al movimiento balístico ($\alpha = 1$). Esto implica que los shocks en la prima de riesgo griega no se disipan aleatoriamente, sino que exhiben una fuerte persistencia (efecto memoria), validando la hipótesis de dinámicas tipo "arrested" propuestas en la literatura de econofísica (Alvarez-Ramirez et al., 2002). El Error Cuadrático Medio (MSE) obtenido para este ajuste estructural fue de 8.3865, confirmando la alta calidad del modelo para describir la escala temporal del fenómeno.

1.3. Datos y variables

La muestra incluye observaciones diarias del rendimiento del bono a 10 años de Grecia y Alemania, cubriendo el ciclo completo de la crisis de deuda soberana. La variable endógena es el spread o prima de riesgo (diferencia en puntos básicos entre el bono griego y el alemán), una medida directa de la percepción de impago por parte del mercado.

El análisis descriptivo de la variable endógena revela la magnitud extrema del fenómeno estudiado. Durante el periodo de análisis, la prima de riesgo alcanzó un valor máximo de 1987.40 puntos básicos, un nivel insostenible que refleja la ruptura del mercado de bonos. La serie presenta una media elevada y una desviación estándar significativa, con una distribución caracterizada por un exceso de curtosis (colas pesadas), lo que justifica

estadísticamente el rechazo de la hipótesis de normalidad y la elección de distribuciones robustas como la t-Student para el modelado econométrico.

1.4. Modelo GARCH(1,1) Bayesiano

El segundo enfoque modela la volatilidad condicional mediante un proceso GARCH(1,1) con inferencia Bayesiana, implementado a través de programación probabilística en Python (Salvatier et al., 2016). A diferencia de la estimación clásica, este método utiliza algoritmos MCMC (Markov Chain Monte Carlo) para explorar la distribución posterior de los parámetros ω, α, β .

La especificación del modelo es:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad (2)$$

Se empleó una verosimilitud t-Student para capturar las colas pesadas observadas en los retornos financieros durante periodos de estrés (Mantegna and Stanley, 2000).




Figure 2. Volatilidad estimada mediante GARCH Bayesiano frente a los retornos absolutos reales. La línea roja representa la media de la volatilidad posterior inferida.

1.4.1. DIAGNÓSTICO DE CONVERGENCIA COMPUTACIONAL

La calibración se ejecutó utilizando el algoritmo NUTS (No-U-Turn Sampler). El proceso computacional tuvo una duración de 797 segundos para generar un total de 400 muestras (2 cadenas, 100 de tune y 100 de draws cada una).

Es necesario reportar las limitaciones técnicas observadas en los diagnósticos de convergencia:

- El estadístico de Gelman-Rubin ($\hat{R}$) resultó ser mayor a 1.01 para algunos parámetros, indicando que las cadenas no han convergido completamente a la distribución estacionaria.

- El tamaño de muestra efectivo (ESS) fue inferior a 100, lo cual sugiere una autocorrelación alta en las muestras generadas.

A pesar de estas advertencias, derivadas de las restricciones de tiempo de cómputo, la Figura 2 demuestra que el modelo captura correctamente los regímenes de volatilidad ("volatility clustering") de 2011-2012. Un incremento en el número de iteraciones (draws) suavizaría la distribución posterior, pero la señal de riesgo extraída es consistente con la realidad histórica.

1.5. Comparación de Desempeño (MSE)

Finalmente, se comparó la capacidad predictiva y de ajuste de ambos modelos calculando el Error Cuadrático Medio (MSE) sobre sus respectivos dominios. Los resultados numéricos obtenidos son:

Modelo	MSE Reportado	Naturaleza del Error
Difusión (Econofísica)	8.3865	Ajuste a la curva teórica (Ley de Potencia)
GARCH Bayesiano	1692.0925	Validación cruzada Monte Carlo (Volatilidad diaria)

Table 1. Comparativa de errores de ajuste.

Análisis de la Discrepancia: Se observa una diferencia de magnitud significativa entre ambos errores (8.38 vs 1692.09). Esto no implica necesariamente que el modelo GARCH sea "peor", sino que refleja la dificultad intrínseca de predecir la volatilidad diaria exacta en un entorno de crisis extrema, sumado al ruido introducido por la falta de convergencia total de las cadenas MCMC ($\hat{R} > 1.01$).

Conclusión: El modelo de Difusión (Alvarez-Ramirez et al., 2002) presenta una estabilidad estructural superior ($\alpha = 0.9360$, bajo MSE) y es ideal para caracterizar la ineficiencia del mercado a largo plazo. Por otro lado, el modelo GARCH Bayesiano, aunque numéricamente menos preciso en este experimento debido a la complejidad computacional, ofrece una herramienta más rica para la gestión de riesgos operativa, permitiendo cuantificar la incertidumbre de los parámetros en tiempo real.

2. Conclusiones y Líneas Futuras

El análisis realizado sobre la prima de riesgo griega revela la dualidad de los mercados financieros en periodos de crisis. Por un lado, el enfoque de la **Econofísica** ha permitido identificar una estructura de memoria a largo plazo ($\alpha \approx 0.94$), sugiriendo que la volatilidad no sigue un paseo aleatorio, sino que responde a dinámicas persistentes y comportamientos de rebaño.

Por otro lado, el modelo **GARCH Bayesiano**, a pesar de la complejidad computacional y las dificultades de convergencia observadas en las cadenas de Markov, ha demostrado ser una herramienta superior para la monitorización del riesgo a corto plazo, capturando los clústeres de volatilidad reaccionando a la información diaria.

Trabajo Futuro: Para investigaciones posteriores, se propone extender la calibración Bayesiana utilizando servidores de alto rendimiento que permitan aumentar el número de muestras (draws) y cadenas, garantizando así un estadístico $\hat{R} \approx 1.0$. Asimismo, sería relevante aplicar este marco comparativo a otros países periféricos de la

Eurozona para confirmar si este comportamiento super-difusivo es sistémico o idiosincrásico de Grecia.

References

- J. Alvarez-Ramirez, E. Rodriguez, and C. Ibarra-Valdez. Diffusive and arrested-like dynamics in currency exchange markets. *Physica A: Statistical Mechanics and its Applications*, 304(3-4):468–477, 2002. Fuente principal del modelo de difusión analizado.
- M. G. Arghyrou and A. Tsoukalas. The greek debt crisis: Likely causes, mechanics and outcomes. *The World Economy*, 34(2):173–191, 2011.
- T. Bollerslev. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327, 1986. Paper fundacional del modelo GARCH.
- R. N. Mantegna and H. E. Stanley. *Introduction to Econophysics: Correlations and Complexity in Finance*. Cambridge University Press, Cambridge, 2000. Referencia clásica para leyes de potencia y caminatas aleatorias en finanzas.
- J. Salvatier, T. V. Wiecki, and C. Fonnesbeck. Probabilistic programming in python using pymc3. *PeerJ Computer Science*, 2:e55, 2016. Librería utilizada para la inferencia MCMC.

A. Diagnósticos del Modelo Bayesiano

A.1. Especificación de Priors

Para el modelo GARCH(1,1), se seleccionaron las siguientes distribuciones a priori (Priors) basándose en la literatura estándar de econometría financiera, buscando distribuciones poco informativas para permitir que los datos dominen la inferencia:

Parámetro	Distribución A Priori	Justificación
μ (Media)	$\mathcal{N}(0, 1)$	Se asume retorno medio cercano a cero.
ω (Intercepto)	$\text{InverseGamma}(2.5, 1.0)$	Positividad estricta requerida.
α, β (GARCH)	$\text{Beta}(\dots)$	Restricción de estacionariedad ($\alpha + \beta < 1$).
ν (Grados Libertad)	$\text{Gamma}(2, 0.1)$	Permite colas pesadas (t-Student).

Table 2. Resumen de la estructura Bayesiana del modelo.

La elección de estas distribuciones a priori sigue un enfoque *débilmente informativo*, diseñado para imponer restricciones teóricas necesarias sin sesgar excesivamente la inferencia final. A continuación se detalla la lógica detrás de cada selección:

1. **Parámetro de Localización (μ):** Se utiliza una distribución Normal centrada en cero. Dado que estamos modelando variaciones diarias de la prima de riesgo (diferencias), es razonable asumir que el valor esperado a largo plazo tiende a la neutralidad, permitiendo desviaciones simétricas positivas o negativas.
2. **Restricción de Positividad (ω):** El término de intercepto de la varianza no puede ser negativo. La distribución *InverseGamma* es estándar en la literatura de volatilidad estocástica porque su soporte es estrictamente positivo $(0, \infty)$, evitando así varianzas negativas imposibles físicamente.
3. **Estacionariedad y Persistencia (α, β):** Los coeficientes del proceso GARCH representan el peso de las noticias recientes (α) y la persistencia de la volatilidad pasada (β). Ambos deben estar acotados en el intervalo $[0, 1]$. La distribución Beta es la elección natural para variables acotadas en este rango. Además, mediante el uso de `pm.Potential`, se impuso la restricción dura de estacionariedad $\alpha + \beta < 1$, necesaria para que la varianza no explote al infinito a largo plazo.
4. **Colas Pesadas (ν):** Los retornos financieros raramente siguen una distribución Normal perfecta (exceso de curtosis). El parámetro de grados de libertad de la t-Student controla el grosor de las colas. Una distribución Gamma para ν asigna baja probabilidad a valores muy pequeños (varianza infinita) y a valores muy grandes (convergencia a Normal), favoreciendo valores intermedios (típicamente entre 3 y 30) que son característicos de los mercados en crisis.

B. Registro de Ejecución y Validación Numérica

Para garantizar la reproducibilidad de los resultados expuestos en la Sección 1, se adjunta a continuación la salida directa generada por el script de calibración.

Este registro confirma los tiempos de cómputo (797 segundos), los parámetros exactos calibrados ($\alpha = 0.9360$) y detalla las advertencias del muestreador NUTS respecto a la convergencia (R-hat y ESS), justificando la necesidad de mayor potencia computacional discutida en el cuerpo del trabajo.

```

1 python3 vBayes-student-mejorado.py
2 -----
3 --- FASE 1: PREPARACIÓN DE DATOS ---
4 --> Leyendo germany.xlsx...
5     Columna detectada: Bid Yield: Rendimiento bono (oferta) 10 años Germany (%)
6 --> Leyendo greece.xlsx...
7     Columna detectada: Bid Yield: Rendimiento bono (oferta) 10 años Grecia (%)
8 Datos originales Max: 1987.40 bps
9 Datos escalados: Max=51.32 | Tipo=float64
10
11 --- FASE 2: CALIBRANDO MODELO DE DIFUSIÓN ---
12 Exponente de difusión Alpha calibrado: 0.9360
13
14 --- FASE 3: CALIBRANDO MODELO GARCH (MCMC) ---
15 Ejecutando calibración Monte Carlo...
16 Initializing NUTS using adapt_diag...
17 Multiprocess sampling (2 chains in 2 jobs)
18 NUTS: [mu, omega, alpha, beta, nu]
19
20 Progress: 200 Draws, 0 Divergences, Step size 0.001, Grad evals 167
21 Sampling Speed: 4.00 s/draws, Elapsed: 0:13:16
22 Progress: 200 Draws, 0 Divergences, Step size 0.001, Grad evals 191
23 Sampling Speed: 3.49 s/draws, Elapsed: 0:11:33
24
25 Sampling 2 chains for 100 tune and 100 draw iterations (200 + 200 draws total) took 797 seconds.
26 We recommend running at least 4 chains for robust computation of convergence diagnostics
27 The rhat statistic is larger than 1.01 for some parameters. This indicates problems during sampling.
28 The effective sample size per chain is smaller than 100 for some parameters.
29
30 Generando simulaciones predictivas (Validación Monte Carlo)...
31 Sampling: [obs]
32 Sampling ... 100% 0:00:00 / 0:00:00
33
34 =====
35     COMPARACIÓN DE MODELOS (MSE AUTOMÁTICO)
36 =====
37 MODELO 1: DIFUSIÓN (ECONOPHYSICS)
38 -> MSE: 8.3865
39
40 MODELO 2: GARCH BAYESIANO (MONTE CARLO)
41 -> MSE: 1692.0925
42 -----
43 Resultados guardados en analisis_grecia_calibracion.mse

```

Listing 1. Salida por terminal del proceso de calibración

Enlace al repositorio con el código fuente, datos y más: <https://github.com/Leonin04/ModelosComplejosModelosDinamicos>